面向 CODESYS 平台的 ST 代码自动生成系统

——自研 Agent Harness 与现有框架的四设置对比

报告人

计算机学院
浙江大学

2026 年 11 月 9 日

问题：让大模型写出”真的能跑”的 PLC 代码

任务

输入自然语言需求 + 接口表 + LTL 规约
输出可直接在 CODESYS 编译并运行的 **IEC 61131-3 结构化文本（ST）**

三个难点

- 语法/工程结构：DUT、Standard 库、调用图
- 行为语义：状态机、定时器、边沿、优先级
- 评测可信：需要**真实执行**而非文本相似

为什么不能只看”像不像”

- 编译通过 $\neq$ 行为正确：差一拍、优先级错都会”看起来对”
- 自研解释器又会引入”不支持某语法”的假失败

判定标准

必须来自**真实 CODESYS 编译 + 仿真运行**，而不是文本相似度或自研解释器

数据集：可编译、可执行、可追溯

规模

- **30 题**：公共 20 + 自建 10
- 难度：easy 9 / medium 12 / hard 9
- **75 条 LTL 规约**（2.5 条/题）
- **54 组用例 / 199 个扫描步**

每题包含

中英需求 · 结构化接口（含 DUT）· LTL 规约 · 行为用例 · **可编译的参考实现**

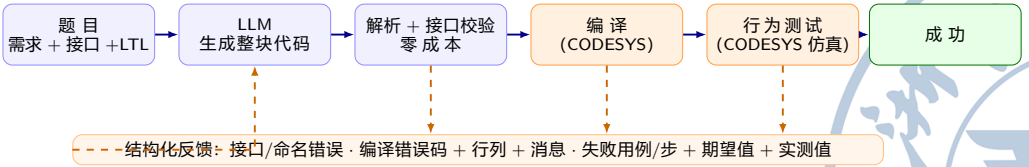
质量门槛：先证明”题可做、用例对”

- 参考实现 **30/30** 编译通过
- 参考实现 **30/30** 通过自己的用例
- 首轮自检修正 **16 处**用例/参考实现缺陷

用例覆盖

正常流程 · 边界条件 · 优先级冲突 · 错误处理；**每步写明测试目的**，并关联到 LTL 规约

系统架构：编译与仿真两道闸门 + 结构化反馈



上下文与成本控制

- 只保留最近 2 轮对话
- 编译错误按 (code, text) 去重计数
- 测试只回传首个失败步

终止条件

- 通过 / 5 轮 / 代码无变化
- 失败签名连续 2 次相同
- `tool_error` 单列，不计入模型

CODESYS 接入：用官方运行时，而不是自研解释器

codesys/compile：编不编得过

- 模板工程 + DUT + Standard 库注入
- `auto_wire`：生成隐藏调用者，让每个 POU 真正进入编译图
- 返回错误码 + 行列 + 中文消息
- 单次约 **13 s**

codesys/simulate：跑起来对不对

- 用例编译成 PLC 内**自测驱动**
- 逐拍设输入、断言输出、记录实测值
- 语义与编译器一致，无" 不支持语法"
- 单次约 **24 s**

设计取舍

编译闸门（实测约 13 s）比仿真闸门（约 24 s）便宜一半，且格式/接口错误在**零成本预校验**就被拦下；对弱模型，多数修复轮次消耗在编译反馈上（Codex+Qwen 首轮 25/30 未编译通过）.

实验设置：2×2 公平对比

	DeepSeek	Qwen
Codex CLI	实验 1	实验 2
自研 harness	实验 3	实验 4

规模

30 题 × 4 设置 = **120 次运行**
每题最多 5 轮；`tool_error` 已重试至 **0**

公平性约束

- 同一 DMXAPI 网关、同一模型快照
- 同一提示、同一反馈文本、同一轮次上限
- 同一 CODESYS 模板与 worker、同一编译/测试管线
- Codex 包装成相同的 `chat(messages)` 接口，差异只在生成组织方式

结果：DeepSeek 下持平，Qwen 下自研显著更好

框架	模型	首次编译	测试通过	平均轮次	输入 tokens
自研	DeepSeek	96.7%	**83.3%**	1.77	75k
自研	Qwen	76.7%	**66.7%**	2.53	131k
Codex	DeepSeek	100.0%	**83.3%**	1.70	565k
Codex	Qwen	16.7%	**33.3%**	4.00	1633k

质量

DeepSeek 两框架测试通过率**持平**（83.3%），自研最终编译 100%

成本

自研输入 token 仅为 Codex 的 **13%**（75k vs 565k），耗时约 **48%**

鲁棒性

Qwen 经 Codex 首轮编译仅 16.7%，18/30 题耗尽 5 轮

分析：框架 × 模型存在强交互

为什么 Qwen 经 Codex 会崩

- 首轮普遍非 IEC 语法：C6 140 次（把 := 写成 =、用 !）
- 遗漏 VAR_IN_OUT 参数、非法 DUT
- 每轮修复成功率低 → 轮次耗尽

自研为何更稳

- 块格式 + 接口预校验把错误挡在编译前
- 反馈短、聚焦单点，弱模型也能迭代

剩余失败集中在行为语义

- 状态机（五工位、柔性加工）
- 定时/边沿（焊缝去抖、自动门、交通灯）
- 典型症状：差一拍、优先级未覆盖

结论

框架与模型需要**匹配调优**；" 更强的 agent 框架对任意模型都更好" 不成立.

总结与局限

已完成

- 30 题数据集：LTL 规约 + 行为用例 + 参考实现
- 自研 harness：编译/仿真双闸门闭环
- CODESYS 编译与仿真服务，可整体迁移
- 四设置公平评测，自动测试（加分项）

局限与后续

- 每题仅采样 1 次，存在方差
- LTL 未机器验证；用例覆盖有缺口
- 下一步：接入 PLCVerif、补强用例覆盖、多平台验证

一句话结论：**把”能不能编译、跑得对不对”做成结构化反馈**，弱模型也能被推上来；框架与模型需要匹配调优.

谢谢，请指正